Data spit

Quiz →
k-means math
Data spit theory

→ train → 70% — better
↳ train এর সাথে আরো এক
→ validation → 15%
(training এর মধ্যে)
→ test → 15%

} Student

আগের model সবকিছুর train এ valo output দিচ্ছে but testing এ তার performance দিতে পারছে না।

(i) there is no separate test data —

(ii) Data distribution (improper) → variety আসে না

(iii) Data leakage possibility → Performance সবকিছু এর training এর ~~সময়~~ dataset এ দিয়ে আসবে (leak হয়)।

Data ~~Augment~~

Data fake → then split → train (এর মধ্যে আসে না), test

Solve for this problem

(i) Proper data spliting

(ii) stratified sampling → এর 80 region কে strata এর random sampling করে মাধ্যমে 10 এর কাছাকাছি নিবেন। এবং তাহলে validate করতে পারবে।

(iii) cross validation

Scenario → আমার data split করে কিভাবে problem এবং solution দিব?